

□ Microsoft Online Yaz Stajı: RAG Projesi Öğrenim ve Video Sunum Rehberi

Bu rehber, geliştirdiğimiz Microsoft Foundry Local & SQLite Tabanlı Çevrimdışı RAG Sohbet Asistanı projesini tam olarak anlayan, mantığını kavrayan ve staj videolarında/sunumlarında kendinden emin bir şekilde anlatabilmen için hazırlanmıştır.

□ 1. Temel Kavramlar: RAG Nedir ve Neden İhtiyaç Duyulur?

□ Soru: RAG (Retrieval-Augmented Generation) Nedir?

Yanıt: RAG; Türkçe karşılığıyla "Geri Getirme Destekli Üretim" demektir. Büyük Dil Modellerinin (LLM) en büyük iki sorununu çözer:

1. Güncel veya Özel Bilgi Eksikliği: Standart dil modelleri senin özel ders notlarını veya şirket belgelerini bilmez.
2. Halüsinasyon (Uydurma Bilgi): Model bilmediği bir soru sorulduğunda mantıklı görünen ama tamamen yanlış cevaplar üretebilir.

RAG'ın Mantığı: Modelin hafızasına güvenmek yerine, sorulan soruyla ilgili belgeleri önce veritabanından bulup getiririz (Retrieve), sonra bu bilgiyi soruyla birleştirip modele veririz (Augment) ve modelin doğru yanıt üretmesini sağlarız (Generate).

□□ 2. Projede Kullandığımız Teknolojiler ve Görevleri

Staj videonda veya raporunda şu 4 ana teknolojiyi anlatacaksın:

1. Microsoft Foundry Local:

- *Ne İş Yapar?*: Yapay zeka dil modellerini internete ihtiyaç duymadan (çevrimdışı/offline) kendi bilgisayarında çalıştırmanı sağlar.
- *Önemi*: Veri gizliliği sağlar, bulut maliyetini sıfırlar.

2. SQLite Veritabanı (`src/database.py`):

- *Ne İş Yapar?*: Belgelerden elde ettiğimiz metin parçalarını ve bunların sayısal vektör karşılıklarını saklar.
- *Önemi*: Sunucusuzdur, tek bir dosya (`rag\_knowledge.db`) halindedir ve çok hızlı çalışır.

3. Sentence-Transformers & Metin Gömmeleri (Embeddings):

- *Ne İş Yapar?*: Kelimeleri ve cümleleri bilgisayarın anlayabileceği sayı dizilerine (vektörlere) dönüştürür.
- *Matematiksel Mantık*: İki cümlenin anlamca ne kadar yakın olduğunu Kosinüs Benzerliği (Cosine Similarity) açısıyla ölçer.

4. Streamlit (`app.py`):

- *Ne İş Yapar?*: Python koduyla hızlıca modern, görsel bir Web Sohbet Arayüzü (Chat UI) oluşturur.

□□ 3. Kodun İç Yapısı: Veri Nasıl İşleniyor?

Yazdığımız projenin adım adım çalışma akışı şöyledir:

...

[Kullanıcı Doküman Yükler (PDF/TXT)]

↓

1. Chunking: Metin 700 karakterlik küçük parçalara bölünür (ingestion.py)

↓

2. Embedding: Parçalar sayısal vektörlere dönüştürülür (ingestion.py)

↓

3. Storage: Metinler ve Vektörler SQLite veritabanına yazılır (database.py)

↓

[Kullanıcı Soru Sorar]

↓

4. Retrieval: Soru vektörleştirilir, Kosinüs Benzerliği ile SQLite'tan en yakın 3 parça çekilir (rag_engine.py)

↓

5. Generation: Sistem istemi + Bağlam + Soru birleştirilir, Türkçe cevapt üretilir (rag_engine.py)

...

□ 4. Staj Videon İçin Örnek Konuşma Senaryosu (Video Script)

Videoda kamera karşısına geçtiğinde veya ekran kaydı alırken şu akışı kullanabilirsin:

□ Giriş (0:00 - 0:30)

> **"Merhaba! Ben Microsoft Online Yaz Stajı programı kapsamındaki projem olan Çevrimdışı Türkçe RAG Asistanı uygulamasını sunacağım. Bu projedeki temel amacımız, kullanıcıların kendi belgelerinden tamamen internetten bağımsız ve güvenli bir şekilde soru-cevap yapabilmesini sağlamaktır."**

□□ Teknik Yapı ve Geliştirme (0:30 - 1:30)

> **"Projemde 4 ana bileşen kullandım:"**

> 1. **"Geri getirme ve depolama için SQLite veritabanını tercih ettim."**

> 2. **"Metinleri anlam vektörlerine dönüştürmek için Sentence-Transformers kütüphanesinden yararlandım ve aramalarda Kosinüs Benzerliği kullandım."**

> 3. **"Modelleme tarafında Microsoft Foundry Local mimarisine uygun yerel çıkarım motorunu entegre ettim."**

> 4. **"Arayüzde ise kullanıcı dostu bir deneyim sunmak için Streamlit ile Türkçe bir sohbet paneli geliştirdim."**

□ Canlı Demo Gösterimi (1:30 - 2:30)

> *(Ekranında `streamlit run app.py` ile açılan uygulamayı göster)*

> **"Şimdi uygulamamızı canlıda test edelim. Sol panelden bir PDF veya TXT dokümanı yüklüyorum. Sistem metni otomatik parçalayıp SQLite veritabanına işliyor. Şimdi sohbet ekranından yüklediğim belgeyle ilgili bir soru soruyorum..."**

> *(Soruyu sor ve yanıtı göster)*

> **"Gördüğünüz gibi sistem sadece dokümanda geçen bilgiyi kullandı, cevabın altına hangi belgeden alındığını gösteren Kaynak Gösterimini (Citation) ekledi ve halüsinasyon görmedi..."**

□ Kapanış ve Kazanımlar (2:30 - 3:00)

> **"Bu staj sürecinde RAG mimarisini, vektör arama matematiksel mantığını, SQLite üzerinde vektör depolamayı ve Sorumlu Yapay Zeka (Responsible AI) ilkelerini uygulamalı olarak deneyimledim. Dinlediğiniz için teşekkür ederim..."**

□ 5. Sık Sorulabilecek Mülakat/Değerlendirme Soruları

1. Soru: "Neden dokümanı tek parça vermek yerine küçük parçalara (Chunk) böldük?"

- Cevap: Dil modellerinin girdi kapasitesi (Context Window) sınırlıdır ve 50 sayfalık belgenin tamamını vermek yavaştır. Küçük parçalara bölerek sadece soruyla alakalı paragrafları çekip verimlilik sağlıyoruz.

2. Soru: "Dokümanda olmayan bir şey sorulursa sistem ne yapıyor?"

- Cevap: Sorumlu Yapay Zeka (Responsible AI) kuralımız gereği, benzerlik skoru düşükse veya bilgi yoksa model bilgi uydurmaz (halüsinasyon görmez) ve "Üzgünüm, sağlanan belgelerde bu soruyla ilgili bilgi bulunmamaktadır" der.